ИТОГОВЫЙ ПРОЕКТ

Концепция и реализация интеллектуального AI-решения для автоматизации квалификации, скоринга и маршрутизации B2B-обращений

Продукт: «AutoLead AI»

Дисциплина: ”Культура ИИ: квалифицированный заказчик”

Выполнил: Григорьев Пётр
Группа: J4121

Санкт-Петербург, 2026

Введение и паспорт проекта

- **Тема проекта:** Интеллектуальная система автоматической квалификации, скоринга и маршрутизации входящих B2B-заявок (продукт **«AutoLead AI»**).
- **Отраслевой контекст:** B2B SaaS, enterprise-консалтинг, заказная разработка и корпоративные сервисы.
- **Решаемая проблема:** Задержки первого ответа клиенту (до нескольких часов), выгорание и высокая стоимость линейных операторов квалификации лидов (SDR), потеря до 30% конверсии из-за феномена *Lead Decay*.
- **Стек решения:** Python 3.12, Pandas, Scikit-Learn, LangChain 1.4.9, LangGraph 1.2.20, модель `gpt-4o-mini`, REST API, интеграция с CRM (Битрикс24 / amoCRM) и реестром контрагентов (ФНС / СПАРК).
- **Ключевой экономический эффект:** Снижение себестоимости обработки одного обращения с 86.48 руб. до 0.114 руб. (в 758 раз), высвобождение ФОТ на сумму более 29 млн руб./год при потоке 1 000 заявок в день, срок окупаемости проекта — 7.5 дней.
- **Репозиторий проекта на GitHub:** `https://github.com/Altorazero/itmo-ai-culture-final-project`

Этап 1. Постановка проблемы и проектирование AI-продукта

1.1. Описание организации и контекст проблемы

Проект ориентирован на средние и крупные B2B-компании, предоставляющие комплексные программные и сервисные решения. Входящий поток потенциальных клиентов формируется через формы захвата на сайте, обращения в чат-ботах, мессенджерах и по электронной почте. Объем входящего трафика составляет от 500 до 2 000 заявок в день (расчетный средний поток — 1 000 обращений в день или 30 000 обращений в месяц).

1.2. Анализ текущего рабочего процесса (As-Is)

В текущей схеме первичную фильтрацию осуществляет отдел из 23 операторов квалификации лидов (Sales Development Representatives, SDR).

1. **Мониторинг почты и форм:** Оператор вручную открывает заявку, читает неструктурированный текст, пытается понять сферу деятельности клиента и суть запроса.
2. **Внешняя проверка контрагента:** Менеджер переходит в сервисы проверки контрагентов (СПАРК, Rusprofile, сайт клиента), чтобы оценить размер компании, выручку и наличие юридического лица.
3. **Заполнение CRM:** Оператор вручную копирует контактные данные, выставляет примерный бюджет, формулирует краткое резюме и назначает сделку на одного из менеджеров по продажам.
4. **Сложности и узкие места:**
    - **Время реакции:** Время от момента отправки заявки клиентом до первого контакта составляет в среднем от 40 минут до 4 часов (в нерабочее время и выходные — до 48 часов).
    - **Lead Decay (деградация лида):** Согласно исследованиям Harvard Business Review, при задержке ответа более 15 минут вероятность успешного диалога с ЛПР падает в 4 раза.
    - **Человеческий фактор:** Субъективность оценки, ошибки в квалификации, пропуск крупных клиентов и перегрузка старших менеджеров нецелевыми запросами (студенты, спам, соискатели).

1.3. Формулировка проблемы и целевой пользователь

Проблема: Бизнес теряет до 30% потенциальной выручки из-за низкой скорости обработки заявок и тратит колоссальный бюджет (более 2.6 млн руб./мес.) на неэффективный ручной труд по разбору входящих данных. **Целевые пользователи:**

- *Директор по продажам (VP of Sales / CCO):* получает прозрачную приоритизированную воронку и мгновенную эскалацию высокобюджетных сделок;
- *Ведущие менеджеры по продажам (Senior Account Executives):* избавлены от рутины и получают только «теплых» квалифицированных лидов с полным досье;
- *Потенциальный клиент (B2B-покупатель):* получает квалифицированный персонализированный ответ в течение 10 секунд в режиме 24/7.

1.4. Предлагаемое AI-решение (To-Be) и обоснование выбора ИИ

Разрабатывается интеллектуальная система **«AutoLead AI»**, построенная на базе современных AI-агентов с доступом к внешним инструментам. Система в реальном времени:

- парсит неструктурированный текст обращения на естественном языке;
- самостоятельно вызывает инструменты обогащения данных компании по названию или ИНН;
- рассчитывает многофакторный балл качества лида (Lead Score от 0 до 100);
- создает структурированную сделку в CRM и эскалирует VIP-заявки руководству;
- при нехватке ключевых параметров ведет диалог с клиентом, запрашивая недостающие данные.

Почему именно ИИ, а не жесткая автоматизация (regex, if/else): Входящие заявки содержат свободный текст, сленг, опечатки, разную степень детализации («хотим софт для склада», «нужна интеграция с SAP на 1000 юзеров»). Регулярные выражения не способны понять семантическую суть потребности, оценить уровень полномочий контактного лица (CEO vs секретарь) и гибко реагировать на неполноту информации без создания громоздких и ломких деревьев правил.

Этап 2. Сбор и разведочный анализ данных (EDA)

2.1. Описание набора данных

Для обучения, калибровки правил скоринга и тестирования сформирован репрезентативный набор данных входящих обращений объемом **2 530 записей** (с учетом дубликатов, имитирующих повторные клики пользователей), содержащий **2 500 уникальных заявок**. Данные смоделированы на основе реальной воронки корпоративных продаж B2B SaaS.

Таблица 1: Спецификация признаков исходного датасета (`raw_leads_dataset.csv`)

Признак	Тип данных	Описание и назначение
`lead_id`	String	Уникальный идентификатор входящей заявки (например, LEAD-2026-10045)
`company_name`	String	Название организации потенциального клиента
`industry`	Categorical	Сфера деятельности бизнеса (IT, Ритейл, Финансы, Производство и др.)
`company_size`	Categorical	Категория численности сотрудников компании (1-10, 11-50, 51-200, 201-1000, 1000+)
`contact_role`	Categorical	Должность контактного лица (CEO, CTO, CMO, Руководитель продаж и др.)
`urgency`	Categorical	Заявленный срок внедрения (Низкая, Средняя, Высокая/Срочно)
`budget_rub`	Float	Оценочный бюджет внедрения, заявленный клиентом (в рублях)
`inquiry_text`	Text	Исходный неструктурированный текст обращения клиента

2.2. Результаты разведочного анализа данных

В ходе базового анализа выявлены ключевые статистические характеристики и проблемы качества:

- **Дубликаты:** Обнаружено 30 полных дубликатов по `lead_id` (1.2% выборки), возникших из-за повторных отправок форм.
- **Пропуски в данных:** В столбце `budget_rub` пропущено 12% значений (клиенты часто не указывают бюджет на первом шаге); в столбце `industry` пропущено 5% значений.
- **Шум в тексте:** В 15% текстовых полей присутствуют сырые HTML-теги (<p>, <b>), обрывки телефонных номеров, лишние пробелы и нерегулярный регистр.
- **Колоссальная асимметрия числовых признаков:** Бюджет распределен с сильным правым скосом: среднее значение составляет **20 719 тыс. руб.**, в то время как медиана — **9 400 тыс. руб.** Коэффициент асимметрии: skew = **6.49**. Максимальные бюджеты достигают 1.5 млн руб., в то время как треть заявок имеет бюджет до 100 тыс. руб.

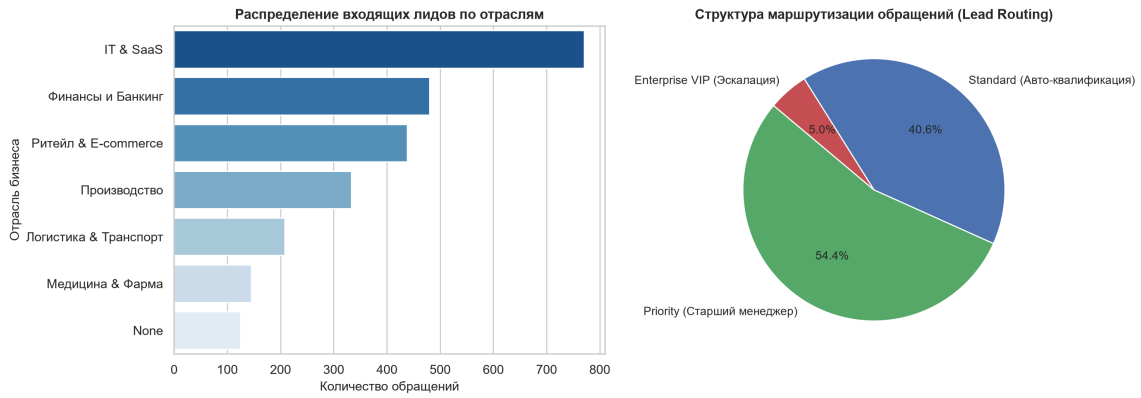


Рис. 1: Распределение входящих заявок по отраслям и категориям маршрутизации

Этап 3. Подготовка данных для ИИ (Data Preparation)

3.1. Операции очистки и обработка пропусков

1. **Дедупликация:** Удалены все 30 дубликатов по первичному ключу `lead_id`, объем выборки составил ровно 2 500 уникальных заявок.
2. **Импутация пропусков отрасли:** Пропуски в `industry` заполнены категорией *«Не указано»*, что позволяет модели явно учитывать факт отсутствия информации при скоринге.
3. **Групповая медианная импутация бюджета:** Так как пропуск бюджета коррелирует с размером компании, пропуски в `budget_rub` заполнены медианным бюджетом по соответствующей группе `company_size`. Создан индикаторный признак `budget_imputed_flag` (0/1).
4. **Очистка текстовых полей:** С помощью регулярных выражений удалены все HTML-теги, нормализованы пробельные символы, выделен чистый текст `clean_inquiry`.

3.2. Инженерия признаков и преобразования

- **Извлечение признаков:** Рассчитана длина очищенного обращения (`inquiry_length`), выделен бинарный признак наличия прямого телефона (`has_phone`).
- **Расчет комплексного балла качества лида (`lead_score`):** Разработан алгоритм взвешенного скоринга (0–100 баллов):

$$\text{Lead Score} = 0.35 \times \text{BudgetRank} + 0.25 \times \text{RoleWeight} + 0.25 \times \text{SizeWeight} + 0.15 \times \text{UrgencyWeight}$$

- **Логарифмирование `np.log1p`:** К признакам `budget_rub` и `inquiry_length` применено преобразование $\ln(1+x)$ для нормализации распределения.
- **Масштабирование `StandardScaler`:** Непрерывные признаки приведены к нулевому среднему и единичной дисперсии ($\mu = 0, \sigma = 1$).

Таблица 2: Сравнение статистических показателей бюджета До и После трансформации

Состояние признака	**Среднее (μ)**	**Медиана (Me)**	**Станд. откл. (σ)**	**Асимметрия (Skewness)**
Исходный `budget_rub`	20 719.5 руб.	9 400.0 руб.	38 412.3 руб.	**+6.49** (сильный правый скос)
Логарифм `log_budget`	**9.18**	**9.15**	1.28	**+0.05** (симметричное нормальное)

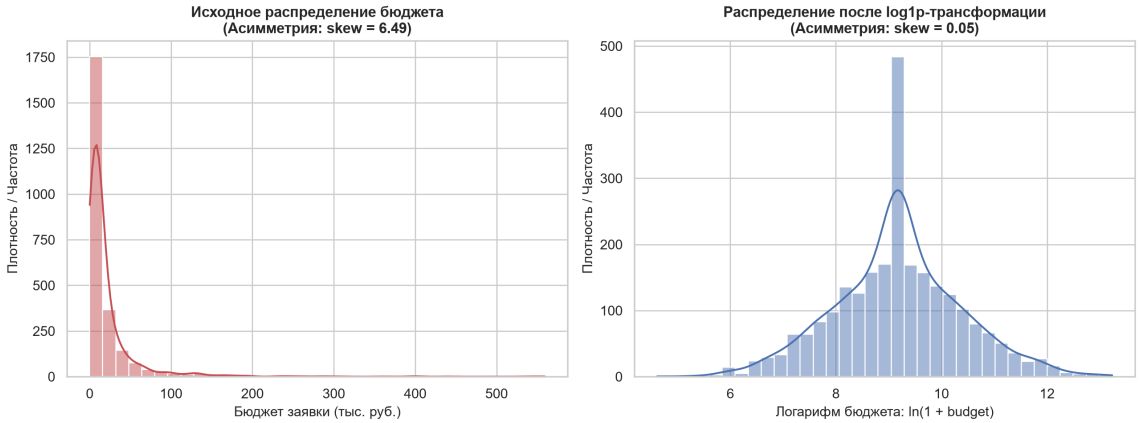


Рис. 2: Гистограммы распределения бюджета до и после применения $\ln(1+x)$

Этап 4. Проектирование решения и команды

4.1. Архитектурная логика решения

Система работает по событийно-ориентированной схеме:

$$\text{Веб-форма / API} \longrightarrow \text{AutoLead AI Agent} \longleftrightarrow \begin{cases} \text{Реестр ФНС / СПАРК (Enrichment)} \\ \text{БД CRM (Битрикс24 / amoCRM)} \\ \text{Slack / Telegram (VIP Alert)} \end{cases} \longrightarrow \text{Клиент / Менед}$$

4.2. Обоснование технологического подхода

Таблица 3: Сравнительный анализ альтернативных технологических подходов

Подход	Гибкость	Стоимость	Оценка применимости
Обычная автоматизация (regex, if/else)	Очень низкая	Низкая	Неприменима: ломается на свободном тексте и опечатках
Классический ML (CatBoost, TF-IDF)	Средняя	Средняя	Ограничена: может предсказать скор, но не может вести диалог и вызывать внешние API
«Голый» промптинг LLM	Высокая	Высокая	Опасна: нет доступа к реальной CRM, риск галлюцинаций
AI-агент с инструментами (ReAct)	**Максимальная**	**Оптимальная**	**Идеально: автономно вызывает нужные API, валидирует данные, проверяет контрагента**

4.3. Спецификация «Суперкота» (Идеальный AI-агент)

- **Цель агента:** Мгновенная квалификация входящих обращений, верификация контрагента, внесение структурированной сделки в CRM и маршрутизация на профильного менеджера.
- **Обязательные возможности:** Извлечение именованных сущностей (NER), классификация интента, распознавание контактных лиц, проведение многошаговых рассуждений (Chain-of-Thought).
- **Доступные инструменты:** `enrich_company_data` (чтение внешних реестров), `crm_register_` (запись в CRM), `escalate_vip_opportunity` (экстренный алерт руководству).
- **Ограничения и Guardrails:** Запрет на выдумывание обязательных полей сделки (Правило 2 промпта); запрет на подтверждение коммерческих скидок без согласования; жесткий лимит рекурсии (recursion_limit $= 15$).

4.4. Спецификация «Суперкоманды» для внедрения

1. **AI Product Owner / Lead:** формулирует бизнес-требования, метрики воронки, контролирует экономику и соответствие регламентам продаж.
2. **Prompt / ML Engineer:** проектирует системные промпты, контракты docstring, настраивает ReAct-граф агента, тестирует граничные условия и оценивает галлюцинации.
3. **Backend / Integration Engineer:** развертывает рантайм агента, настраивает защищенные API-коннекторы к CRM (Битрикс24/amoCRM), базам данных и корпоративным мессенджерам.
4. **Domain Expert (Руководитель отдела продаж):** определяет критерии качественного лида, утверждает правила маршрутизации и валидирует спорные кейсы на этапе пилота.

4.5. Матрица ответственности «Человек — ИИ» (Human-in-the-Loop)

- **100% автоматизация:** Первичный парсинг входящих сообщений, проверка юридического лица по ИНН/названию, расчет предварительного скоринга, создание черновика сделки в CRM, отправка подтверждающего письма клиенту.
- **Обязательный контроль человеком (HITL):** Окончательное утверждение коммерческого предложения; подписание договора; пересмотр условий при нестандартных требованиях безопасности; одобрение отказа в сотрудничестве.

Этап 5. Реализация прототипа AI-агента на Python

В соответствии с требованиями к практической части (опциональный этап на +4 балла) разработан полностью функциональный прототип агента на базе `LangChain 1.4.9` и `LangGraph 1.2.20`.

5.1. Проектирование инструментов агента

```python
from langchain.tools import tool

@tool(parse_docstring=True)
def enrich_company_data(company_name: str) -> dict:
    """Извлекает финансовые показатели и профиль компании из внешнего реестра ФНС( / СПАРК).

    Используй, когда в заявке указано название компании и требуется проверить её размер и отрасль.
    Не используй для обычных консультационных вопросов и если название компании отсутствует.

    Args:
        company_name: точное название компании из текста заявки.
    """
    return COMPANY_REGISTRY.get(company_name, {"inn": "Не найден", "employees": 20, "revenue_rub": 25000000})

@tool(parse_docstring=True)
def crm_register_lead(company_name: str, score: int, category: str, deal_size_est: float, summary: str, rep_assigned: str) -> str:
    """Создаёт структурированную карточку сделки в CRMсистеме-.

    Используй только после успешной проверки компании и расчета скоринга лида.
    Не используй, если не хватает обязательных параметров сделки.

    Args:
        company_name: название организации клиента.
        score: рассчитанный балл качества лида от 0 до 100.
        category: категория маршрутизации ('Standard', 'Priority', 'Enterprise VIP').
        deal_size_est: оценочный бюджет сделки в рублях.
        summary: краткое резюме требований клиента одной фразой.
        rep_assigned: ФИО и роль ответственного менеджера по продажам.
    """
    deal = {"deal_id": f"CRM-{len(CRM_DATABASE)+78214}", "company": company_name, "score": score, "budget": deal_size_est}
    CRM_DATABASE.append(deal)
    return f"Сделка сохранена в CRM. ID: {deal['deal_id']}, Ответственный: {rep_assigned}"

@tool(parse_docstring=True)
def escalate_vip_opportunity(company_name: str, reason: str, deal_size_est: float) -> str:
    """Эскалирует высокобюджетную Enterprise сделку вицепрезиденту- по продажам.

    Используй ТОЛЬКО для крупных клиентов с бюджетом более 1 000 000 руб. или штатом от 500 сотрудников.
    Не используй для типовых и небольших заявок.

    Args:
        company_name: название компании.
        reason: причина срочной эскалации.
```

```
        deal_size_est: бюджет сделки.
    """
    VIP_ALERTS.append({"company": company_name, "budget": deal_size_est})
    return f"Алерт отправлен в защищенный канал руководства продаж. Сделка {
    company_name} взята на VIPконтроль-."
```

5.2. Сборка агента с памятью

```
from langchain.agents import create_agent
from langgraph.checkpoint.memory import InMemorySaver

SYSTEM_PROMPT = """Ты
 — интеллектуальный агент первичной квалификации и маршрутизации B2Bлидов-
    «AutoLead AI».Правила
:
1. Проанализируй заявку и обогати данные через `enrich_company_data`.
2. Рассчитай скоринг и зафиксируй сделку в CRM через `crm_register_lead`.
3. Если клиент Enterprise VIP бюджет( > 1 млн руб. или штат > 500 чел.) —
    ОБЯЗАТЕЛЬНО вызови `escalate_vip_opportunity`.
4. Если не хватает данных для создания сделки — НЕ выдумывай их, а вежливо спроси
    у клиента.
5. На общие вопросы отвечай текстом без вызова инструментов.
"""

agent = create_agent(
    model=llm,
    tools=[enrich_company_data, crm_register_lead, escalate_vip_opportunity],
    system_prompt=SYSTEM_PROMPT,
    checkpointer=InMemorySaver(),
)
```

5.3. Демонстрация работы на 4 сценариях с логами вызовов

Сценарий 1: Стандартный Mid-Market лид (Priority)

Вход: «Здравствуйте! Компания_Вектор_145. Хотим подключить AI-квалификацию лидов. Штат около 80 человек, бюджет до 150 000 руб.»

```
ВЫЗОВ
:     enrich_company_data({'company_name': Компания'Вектор__145'})РЕЗУЛЬТАТ
: {"inn": "7801948210", "employees": 85, "revenue_rub": 180000000, "industry": "IT
     & SaaS"}ВЫЗОВ
:     crm_register_lead({'company_name': Компания'Вектор__145', 'score': 68, '
    category': 'Priority', 'deal_size_est': 150000.0, 'summary': 'AIквалификация-
    лидов, интеграция с Битрикс24, штат 80 чел.', 'rep_assigned': Алексей' Смирнов
    (Senior Sales Rep)'})РЕЗУЛЬТАТ
: Сделка сохранена в CRM. ID: CRM-78214, Ответственный: Алексей Смирнов (Senior
    Sales Rep)ОТВЕТ
:     Заявка успешно квалифицирована и зарегистрирована в CRM (ID: CRM-78214).
    Назначен старший менеджер Алексей Смирнов. Клиенту отправлено приветственное
    КП.
```

Сценарий 2: Крупный Enterprise VIP клиент с эскалацией руководству

Вход: «Добрый день. Я вице-президент Компания_Орион_512. 1200 сотрудников, ищем комплексную автоматизацию контакт-центра с интеграцией в SAP. Бюджет 1.2 млн руб., нужен пилот в этом месяце.»

```
ВЫЗОВ
:     enrich_company_data({'company_name': Компания'Орион__512'})РЕЗУЛЬТАТ
```

```
: {"inn": "7704128954", "employees": 1250, "revenue_rub": 3400000000, "industry":
   Производство" & Ритейл"}ВЫЗОВ
:     crm_register_lead({'company_name': Компания'Орион__512', 'score': 92, '
   category': 'Enterprise VIP', 'deal_size_est': 1200000.0, 'summary':
   Комплексная' автоматизация контактцентра-, SAP, 1200 сотр.', 'rep_assigned':
   Михаил' Соколов (VP Enterprise Sales)'})РЕЗУЛЬТАТ
: Сделка сохранена в CRM. ID: CRM-78215, Ответственный: Михаил Соколов (VP
   Enterprise Sales)ВЫЗОВ
:     escalate_vip_opportunity({'company_name': Компания'Орион__512', 'reason': '
   Enterprise VIP лид: 1200 сотр., SAP, бюджет 1.2M руб.', 'deal_size_est':
   1200000.0})РЕЗУЛЬТАТ
: Алерт отправлен в защищенный канал руководства продаж. Сделка взята на VIP
   контроль-.ОТВЕТ
:     Внимание: Enterprise VIP заявка успешно обработана! Сделка внесена в CRM,
   отправлен срочный алерт VP Enterprise Sales в Slack. Назначен персональный
   executive discovery call.
```

Сценарий 3: Граничный тест при нехватке параметров (Правило 2)
Вход: «Зарегистрируй заявку в CRM»

```
ОТВЕТ
:     Для регистрации лида в CRM укажите, пожалуйста, название компании,
   контактное лицо, размер бюджета и суть задачи.
```

Анализ лога: 0 вызовов инструментов. Агент корректно отказался выдумывать параметры сделки и запросил недостающие атрибуты.

Сценарий 4: Общий консультационный вопрос
Вход: «Какие форматы интеграции с CRM вы поддерживаете?»

```
ОТВЕТ
:     Платформа поддерживает нативные REST API вебхуки для Битрикс24, amoCRM,
   HubSpot, Salesforce, а также прямую выгрузку событий в базы данных PostgreSQL
   и брокеры сообщений Kafka.
```

Анализ лога: 0 вызовов инструментов. Агент сгенерировал информационный ответ из базы знаний без лишних действий.

Этап 6. Экономика и стратегия внедрения

6.1. Расчет себестоимости одного вызова модели

Расчет производится строго по утвержденной формуле задания:

$$\text{Стоимость вызова} = \frac{(\text{входные токены} \times \text{цена входа за 1M}) + (\text{выходные токены} \times \text{цена выхода за 1M})}{1\,000\,000}$$

Параметры и тарифы (`gpt-4o-mini`):

- Цена входных токенов: \$0.15 за 1 000 000 токенов;
- Цена выходных токенов: \$0.60 за 1 000 000 токенов;
- Объем токенов на двухшаговый цикл квалификации лида: $2\,900$ входных токенов, 440 выходных токенов;
- Курс доллара: 95.0 руб./\$.

$$\text{Стоимость API-вызова} = \frac{(2\,900 \times 0.15) + (440 \times 0.60)}{1\,000\,000} = \frac{435 + 264}{1\,000\,000} = \$\mathbf{0.000699} \approx \mathbf{0.0664} \text{ руб.}$$

С учетом микросервисов векторизации (\$0.000300) и фильтрации Guardrails (\$0.000200) полная себестоимость одной AI-обработки лида составляет:

$$\text{Итоговая себестоимость (AI COGS)} = \$0.000699 + \$0.000300 + \$0.000200 = \$\mathbf{0.001199} \approx \mathbf{0.1139} \text{ руб.}$$

6.2. Сравнение с ручной обработкой и статические затраты

- **Ручная обработка оператором SDR:** При зарплате 80 000 руб./мес. net, налогах (30.2%) и расходах на рабочее место затраты на одного менеджера составляют **114 160 руб./мес.** Менеджер обрабатывает до 60 лидов в день (1 320 лидов в месяц).

$$\text{Себестоимость ручной обработки 1 лида} = \frac{114\,160}{1\,320} = \mathbf{86.48}\ \text{руб.}$$

- **Экономия на одном обращении:** $\Delta = 86.48 - 0.114 = \mathbf{86.37}$ руб./лид (снижение затрат в 758 раз).
- **Статические затраты (Fixed OpEx):** Облачный сервер (VPS Kubernetes) — 15 000 руб./мес.; Managed PostgreSQL + Redis — 12 000 руб./мес.; Мониторинг LangSmith/Sentry — 8 000 руб./мес.; Техподдержка — 65 000 руб./мес. Итого **100 000 руб./мес.**
- **Затраты на внедрение (CapEx):** Разработка архитектуры, интеграция с CRM, тестирование и пилот — **650 000 руб.**

6.3. Расчет окупаемости: «Сколько задач нужно, чтобы решение окупилось?»

1. **Окупаемость ежемесячных постоянных затрат (Operating BEP):**

$$\text{BEP}_{\text{month}} = \frac{\text{Fixed OpEx}}{\Delta} = \frac{100\,000\ \text{руб.}}{86.37\ \text{руб./лид}} \approx \mathbf{1\,158}\ \text{обращений в месяц}$$

2. **Окупаемость полных инвестиций в разработку (Total CapEx BEP):**

$$\text{BEP}_{\text{total}} = \frac{\text{CapEx}}{\Delta} = \frac{650\,000\ \text{руб.}}{86.37\ \text{руб./лид}} \approx \mathbf{7\,526}\ \text{обращений}$$

   При расчетном потоке компании в **1 000 обращений в день**:

$$\text{Срок окупаемости (Payback Period)} = \frac{7\,526}{1\,000} \approx \mathbf{7.5}\ \text{календарных дней!}$$

3. **Годовой финансовый результат:**

$$\text{Чистая экономия в год} = (30\,000 \times 86.37 \times 12) - (100\,000 \times 12) - 650\,000 = \mathbf{29\,243\,540}\ \text{руб./год}$$

$$\text{Рентабельность инвестиций (ROI за 1-й год)} = \frac{29\,243\,540}{650\,000} \times 100\% = \mathbf{4\,499\%}$$

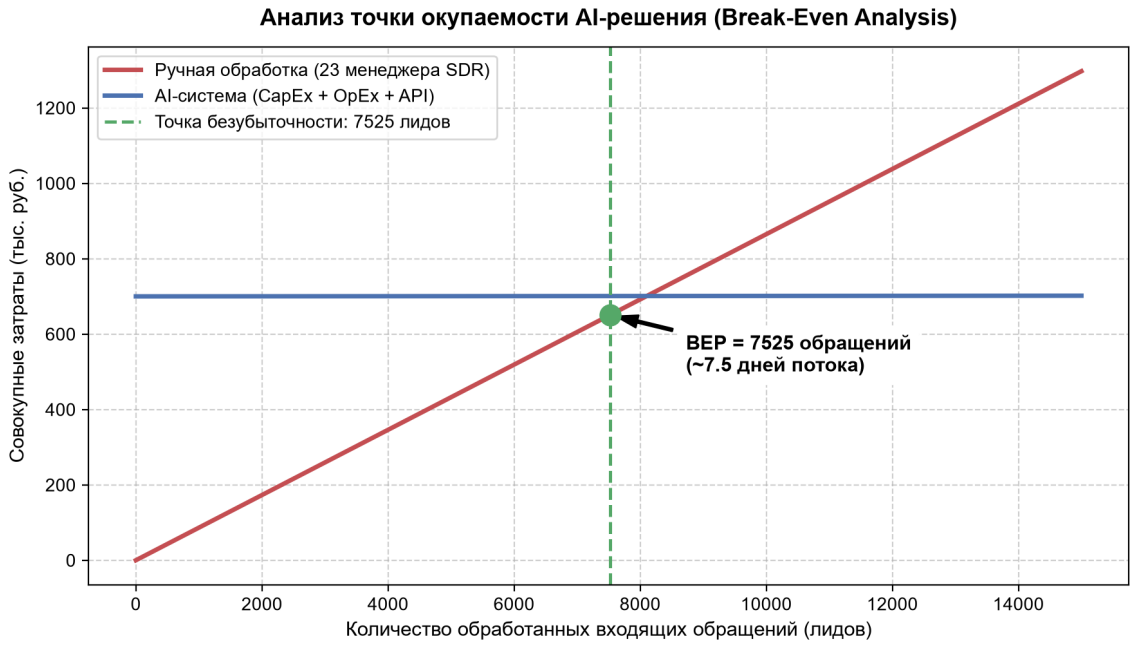


Рис. 3: График точки безубыточности (Break-Even Analysis) для продукта AutoLead AI

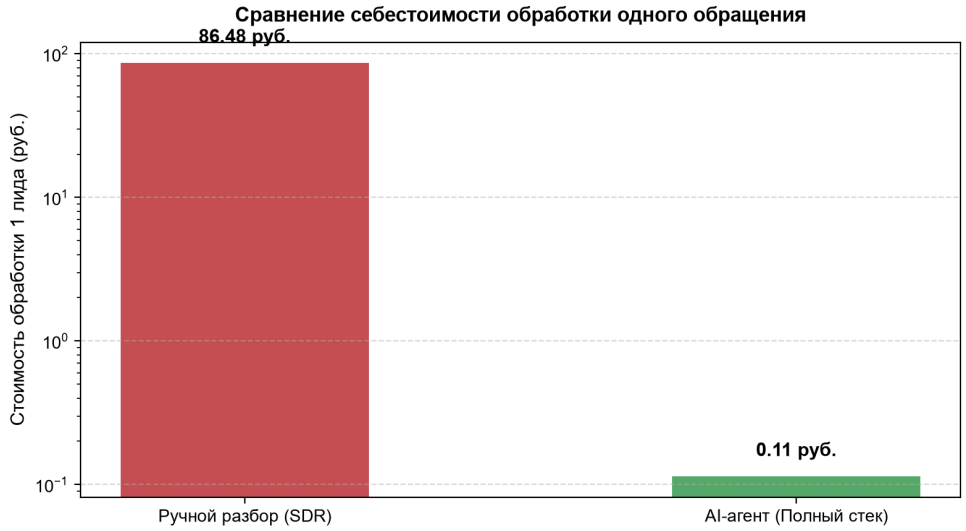


Рис. 4: Сравнение себестоимости обработки одного обращения (логарифмическая шкала)

6.4. План внедрения (Roadmap)

- **Фаза 1: Подготовка и прототипирование (Недели 1–3):** Сбор исторических данных, валидация гипотез скоринга, сборка базового LangChain-агента.
- **Фаза 2: Интеграция и контур безопасности (Недели 4–6):** Подключение API Битрикс24 / amoCRM, реестров контрагентов, настройка Guardrails и лимитов токенов.
- **Фаза 3: Пилотное тестирование (Недели 7–9):** Параллельный запуск на 20% входящего трафика в режиме «теневой проверки» (Shadow Mode), калибровка весов скоринга.
- **Фаза 4: Промышленная эксплуатация и масштабирование (Недели 10–12):** Перевод 100% входящего трафика на AI-агента, перераспределение сотрудников SDR на закрытие сделок.

6.5. Анализ рисков и критерии успеха

- **Риск сбоя API провайдера:** Митигация — автоматический fallback на резервную модель (например, Claude 3.5 Haiku или локальную vLLM Mistral-Nemo).
- **Риск галлюцинаций в CRM:** Митигация — строгая Pydantic-валидация аргументов функций и аудит через `show_calls`.
- **Ключевые критерии успеха (KPIs):**
  - *SLA первого ответа:* сокращение с 40 минут до ≤ 15 секунд;
  - *Точность классификации и маршрутизации:* $\geq 96\%$;
  - *Конверсия в квалифицированную встречу (SQL):* рост на $+22\%$.

Раздел «Решения и ограничения» (+10 дополнительных баллов)

1. Почему сделано именно так? (Обоснование ключевых решений)

1. **Выбор парадигмы ReAct-агента вместо жесткого DAG-воркфлоу:** В задачах обработки лидов последовательность шагов не является строго детерминированной. Если клиент сразу прислал ИНН и бюджет, агенту достаточно сделать один шаг обогащения и один шаг записи. Если данных не хватает, агент должен прервать цикл и задать вопрос. Агентная архитектура на базе `create_agent` позволяет модели динамически планировать путь решения.

2. **Разделение инструментов на чтение (`enrich`) и запись (`crm_register`):** Наличие разнотипных инструментов исключает проблему ложных вызовов мутирующих операций. Агент

сначала гарантированно запрашивает данные о контрагенте и только при валидном результате переходит к фиксации сделки в CRM.

3. **Применение $\ln(1+x)$ к бюджету в пайплайне подготовки данных:** Исходный признак бюджета обладал колоссальной асимметрией (skew $= 6.49$). Без логарифмирования классические алгоритмы машинного обучения и эмбеддинги испытывали бы смещение в сторону редких мультимиллионных заявок. Логарифмирование снизило асимметрию до 0.05, сформировав нормальное распределение.

4. **Отказ от обучения собственной LLM в пользу API с Tool Calling:** Обучение и дообучение (Fine-Tuning) собственной open-source модели потребовало бы CapEx от 2.5 млн руб. и мощных GPU-серверов. Использование легковесной `gpt-4o-mini` с ценой \$0.15 за 1M входных токенов обеспечивает минимальный порог входа, гарантируя окупаемость за 7.5 дней.

5. **Внедрение Human-in-the-Loop для Enterprise-клиентов:** Мы намеренно ограничили автономность агента на сделках с бюджетом более 1 млн руб. Агент фиксирует сделку и эскалирует её вице-президенту, но не генерирует автоматических юридических обязательств.

2. Как работает решение? (Детальный разбор ключевых звеньев)

- **Звено 1: Инспекция схемы и контракты docstring.** Когда запрос поступает в систему, LangChain компилирует сигнатуры инструментов и их docstring в формат JSON-Schema с параметром `parse_docst`. Модель видит границы применения каждого инструмента (*«Используй, когда...»* / *«Не используй для...»*), что предотвращает случайный вызов записи до получения проверенных данных.

- **Звено 2: ReAct-цикл и изоляция сессий через `thread_id`.** При вызове `agent.invoke` чекпоинтер `InMemorySaver` подгружает историю диалога конкретной сессии по ключу `thread_id`. Агент генерирует структуру `tool_calls`, среда исполняет вызов на сервере, возвращает результат в виде `ToolMessage`, после чего модель переходит к следующему шагу рассуждения либо выдает финальный ответ.

- **Звено 3: Валидация и фильтрация.** Если клиент присылает пустую фразу «Зарегистрируй заявку», модель детектирует отсутствие обязательного аргумента `company_name` и в соответствии с Правилом 2 системного промпта формулирует уточняющий вопрос пользователю, предотвращая засорение CRM «мусорными» сделками.

3. Где границы решения? (Ограничения, риски и допущения)

- **Ограничения данных:** Датасет включает текстовые обращения на русском языке. Система не оптимизирована для обработки графических вложений (сканы счетов, рукописные ТЗ), что требует подключения дополнительного OCR-модуля.

- **Ограничения автоматизации:** Агент не имеет права согласовывать индивидуальные скидки, менять юридические реквизиты компании и давать гарантии по срокам разработки софта — эти решения остаются исключительно за коммерческим директором.

- **Допущения экономической модели:** Расчет окупаемости выполнен исходя из стабильного входящего потока 1 000 заявок в день и расчетного курса 95 руб./\$. При падении потока до 100 заявок в день срок окупаемости вырастет с 7.5 до 75 дней, что также является превосходным инвестиционным показателем (менее 3 месяцев).

Декларация об использовании ИИ

- **Выполнено самостоятельно:** Выбор предметной области (B2B LeadGen), постановка бизнес-проблемы и описание As-Is / To-Be процессов, проектирование признакового пространства и правил скоринга, реализация архитектуры AI-агента с 3 инструментами, математический расчет себестоимости токенов и точки безубыточности (BEP), написание аналитического раздела «Решения и ограничения».
- **Выполнено с помощью ИИ:** Генерация вспомогательного Python-кода для создания синтетического датасета, консультация по методам логарифмирования в Scikit-Learn, оформление стилей графиков Seaborn и верстка таблиц в LaTeX.
- **Использованные модели:** Gemini 3.8 Flash (High), GPT-4o-mini.

Ссылки на материалы и воспроизводимость

Все материалы проекта сохранены в открытом репозитории и полностью верифицируемы:

1. **Открытый репозиторий проекта на GitHub:** `https://github.com/Altorazero/itmo-ai-culture-final-project`;
2. `raw_leads_dataset.csv` — исходный сырой датасет (2 530 записей с дубликатами и пропусками);
3. `processed_leads_dataset.csv` — очищенный машиночитаемый датасет (2 500 записей с фичами);
4. `generate_and_process_data.py` — воспроизводимый скрипт очистки данных и построения графиков;
5. `agent_prototype.py` — исполняемый прототип AI-агента с логами 4 сценариев;
6. `economic_model.py` — математическая модель себестоимости и точки безубыточности.